



시험합의서

TVT-A-25-00XX-AG

1. 시험신청일반사항

시험신청번호	VT-A-25-00XX		성적서 구분	TTA 성적서(V), KOLAS 성적서()
시험성적서 및 결과서 발급	온라인 발급(V) 우편 발급() 방문 발급()			
신청기업(기관)명	(주)		사업자등록번호	
대표자			대표자 E-Mail	
대표 전화번호			홈페이지	
주 소	(우편번호)			
현장시험 유무	유/무			
업 무 담 당 자	성 명		전화번호	
	Mobile		E- Mail	
	FAX번호		부서/직급	

2. 시험대상

2.1 시험대상

- 국문명(버전) : 제품명 또는 시험 대상 (v1.0)
- 영문명(버전) : (영문 작성) (v1.0)

2.2. 시험대상 운영환경

1) TC1(음성 외 음향 인식율) 운영환경

소프트웨어 정보		
운영체제	서버	Ubuntu 20.04.6 LTS
	클라이언트	Mac OS Sonoma 16.5
특이사항 (제품구동요구사항)		Python 3.10.12, numpy 1.23.5, pandas 2.1.1, torch 1.11.1 + cu115, scikit-learn 1.2.5, Chrome 122.0.6261.129
하드웨어 정보		
하드웨어 사양	서버	CPU: Intel(R) Xeon(R) Platinum 8259CL CPU @ X.XGHz / RAM: 15.3GB / SSD: 194GB
	클라이언트	CPU: Apple M1 8 Core / GPU: NVIDIA GeForce GTX 1060 / RAM: 16GB / HDD: 512GB
네트워크 환경	TCP/IP	
기타 환경	AWS 클라우드 플랫폼	
기타사항		
- 신청기업(기관)은 시험에 필요한 HW 및 SW를 제공함 - 신청기업(기관)은 시험환경구성, 제품설치 및 기술교육을 지원함		

2) TC2(RAG + LLM 신뢰도) 운영환경


소프트웨어 정보	
운영체제	macOS 15 (Darwin 24.4.0)
특이사항 (제품구동요구사항)	Python 3.8.6, Poetry, ragas 0.0.22, langchain 0.0.348, datasets 2.16.1, chromadb 0.4.22, nltk 3.8.1, beautifulsoup4 4.12.3, OpenAI API Key, LangSmith API Key
하드웨어 정보	
하드웨어 사양	CPU: Apple M1 (또는 동등 사양), RAM: 16GB
네트워크 환경	TCP/IP (인터넷 연결 필수)
기타 환경	LangSmith 플랫폼, OpenAI API 서비스
기타사항	
- 신청기업(기관)은 시험에 필요한 HW 및 SW를 제공함 - 신청기업(기관)은 시험환경구성, 제품설치 및 기술교육을 지원함	

3) TC3(파인튜닝 LLM 정확도) 운영환경


소프트웨어 정보	
운영체제	RHEL Workstation 8.9 for GPU-based Instances (TESLA driver)
특이사항 (제품구동요구사항)	Python 3.8 이상, CUDA Version 12.3, Git, Git LFS, Poetry
실행 패키지 목록	transformers 4.31.0, lm-eval 0.4.2(wandb 제공), bitsandbytes 0.41.1 이상, wandb 0.16.5
하드웨어 정보	
하드웨어 사양	CPU: AMD EPYC 7R32, 24코어/48vCPU, 최대 3.3GHz RAM: 192 GiB DDR4 3200MHz 스토리지: 3800 GB NVMe SSD GPU: NVIDIA A10G Tensor Core GPU x 4 (각 24GB, 총 96GB)
네트워크 환경	TCP/IP (40 Gbps)
기타 환경	AWS 클라우드 플랫폼
기타사항	
- 신청기업(기관)은 시험에 필요한 HW 및 SW를 제공함 - 신청기업(기관)은 시험환경구성, 제품설치 및 기술교육을 지원함	

2.3. 시험 환경 구성도


1) TC1(음성 외 음향 인식율) 시험 환경 구성도



2) TC2(RAG + LLM 신뢰도) 시험 환경 구성도



3) TC3(파인튜닝 LLM 정확도) 시험 환경 구성도



3. 시험기간 : 시험 시작일로부터 X일(Working Day 기준)

(* Working Day란 토요일과 휴일 및 기타 전사적인 업무로 시험업무를 수행할 수 없는 기간을 제외한 나머지 기간을 말하며, 시험일정은 업무관련 사정에 의해 다소 연기될 수 있습니다.)

※ 현장시험 여부 : O/X

(* 현장시험: 시험수행을 위해 TTA 내부가 아닌 외부의 별도 장소에 방문하여 시험을 수행하는 것)

※ 사유: 인공지능 모델 시험으로 원활한 시험환경 제공 및 Data 보안상 필요

4. 시험 기준

1) 시험기준은 시험규격서를 참고한다.

5. 시험 범위

1) 시험범위는 시험규격서를 참고한다.

6. 시험대상, 장비의 제공 및 반환

- 1) 시험장비 및 시험수행 절차는 신청기업(기관)과 TTA의 협의 하에 결정한다.
- 2) 시험대상(소프트웨어)은 신청기업(기관)이 제공한다.
- 3) TTA는 시험 수행을 위한 시험환경을 구축한다.
- 4) 신청기업(기관)은 TTA가 시험 수행을 위한 시험대상 장비, 소프트웨어, 데이터 등을 요청할 경우, 이를 적극적으로 제공한다.
- 5) TTA는 시험 종료 후 반입한 신청기업(기관)의 장비를 반환한다.

7. 인력운용 및 운영시간

1) 시험은 TTA의 법정 근무시간에만 수행되는 것을 원칙으로 한다.

-
- 2) TTA는 시험수행을 위하여 1인 이상의 시험전문가를 투입한다.
 - 3) 신청기업(기관)은 TTA의 요청 시 1인 이상의 시험대상 전문가를 지원해야 한다.

8. 시험성적서 제공

- 1) TTA는 시험종료 시 시험성적서를 신청기업(기관)에게 제공한다.
- 2) TTA는 신청기업(기관)의 시험결과를 신청기업(기관)과의 사전협의 없이 외부에 공개하지 않는다.

9. 시험협조 사항

시험을 위하여 신청기업(기관)은 TTA에 다음 사항을 협조한다.

- 1) 시험대상의 상세규격서 제공
- 2) 신청기업(기관)이 수행한 시험대상에 대한 사전 시험내용 및 관련문서 제공
- 3) 기타 시험수행을 위하여 협조를 요청하는 사항

10. 시험 중단

- 1) 시험대상의 문제점 발생으로 인하여 시험을 더 이상 수행할 수 없을 경우, TTA는 이를 신청기업(기관)에게 통보하고 시험을 중단할 수 있다.
- 2) 신청기업(기관)의 요청 시 TTA는 시험을 중단할 수 있다.
- 3) 시험 중단 시 수수료는 반환하지 않는다.
- 4) 시험 중단 후 신청기업(기관)의 요청에 의해 시험 재개 시, 전체 Working day에서 사용한 Working day를 제외한 기간 동안 시험을 수행한다.

11. 기타 의무사항

- 1) 신청기업(기관)은 시험과정에서 발생한 시험목적 및 내용과 무관한 정보를 이용하여 타사 및 타 제품과의 비교나 우열을 광고하거나 영업활동에 이용 할 수 없다.
- 2) 신청기업(기관)은 TTA 업무와 관련된 정보(장비, 인력 현황 등)를 외부에 공개할 수 없다.

시험규격서

ID	시험 항목	시험 목표 및 기준	예상결과
TC1	XXX 기능 소요시간	<시험목표> 시험대상제품으로 XXXX 기능 실행 시 작업의 소요시간 확인 <시험기준> o 기준: ISO/IEC 25023:2016 - 8.3.1 Time behaviour measures (PTb-3-G: Mean turnaround time) o 산정식: $X = \frac{1}{n} \sum_{i=1}^n (B_i - A_i)$ - A_i: 작업 i의 시작 시간 - B_i: 작업 i의 완료 시간 - n: 측정 횟수 ※ TC1의 시험기준 및 시료는 시험의뢰기업에서 제공	$X \leq 70$
TC2	RAG + LLM 신뢰도	<시험목표> 시험대상제품의 RAG 시스템이 청크 크기 256, 오버랩 20 대비 10% 이상의 신뢰도 개선을 달성하는지 확인 <시험기준> o 기준: RAGAS 평가 프레임워크 Faithfulness 지표 o 산정식: $X = (B - A) / A \times 100$ - A: 기본 설정(청크 크기 256, 오버랩 2)의 Faithfulness 점수 - B: 최적화 설정(청크 크기 1000, 오버랩 50)의 Faithfulness 점수 o 시료: NarrativeQA validation set 100개 샘플 ※ 시료는 {질문, 정답, 문서 URL} 형식의 데이터로 구성	$X \geq 10\%$
TC3	파인튜닝 LLM 정확도	<시험목표> 파라미터 수가 70억개 이하인 오픈소스 LLM을 한국어 데이터셋으로 파인튜닝한 후, KoBEST HellaSwag 벤치마크에서의 성능 개선 확인	$X \geq 47.4\%$



시험합의서

TVT-A-25-00XX-AG

ID	시험 항목	시험 목표 및 기준	예상결과
		<시험기준> - o 기준: KoBEST HellaSwag 벤치마크의 F1 점수 - o 산정식: $X = F1 \times 100$ - F1: EleutherAI의 lm-evaluation-harness로 측정된 KoBEST HellaSwag의 F1 점수 - 10-shot 설정으로 평가 수행 - o 평가 명령어: <code>lm_eval --model hf --model_args pretrained={기본모델},peft={파인튜닝모델},parallelize=True --tasks kobest --num_fewshot 10 --batch_size auto</code>	

※ 각 시험항목별 세부 시험절차는 ‘(붙임)VT-A-25-00XX_시험절차서’ 참조

※ 시험대상 운영환경 및 시험절차는 시험이 완료되기 전까지 TTA와 신청기업(기관)의 협의에 의해 변경될 수 있음

※ 시험 목적이 과제 결과를 검증용인 경우 아래 ‘<수행과제개요>’ 작성

<수행과제개요>

수행 과제명	
과제전담기관	
과거 TTA V&V성적서 발급유무	유/무 (‘유’ 인 경우 성적서 번호 기입)

ID	구분	내용																								
TC1	시험 항목명	위와 동일하게 작성 부탁드립니다.																								
	시험 목표 및 기준	위 내용 작성 후 붙여 넣을 예정입니다.																								
	사전 조건	시험에 사용되는 툴 등의 설치 여부, ~서버 접속 여부 등																								
	시료	시험에 사용되는 데이터의 개수 및 형식 등																								
	반복시험 횟수	N회																								
	시험 절차	1.원천데이터 파일을 확인한다. - 파일 경로/파일명.csv - (예시 이미지) 2. 데이터 전처리 스크립트(~.py)를 실행한다. - 필요 라이브러리 로드 - 관련 데이터 로드 - 필터링, 누락값 제거 등 1) ~데이터 제외 2) ~변수 추가 - Train data 및 Test data 분할(8:2) - 데이터 표준화 수행 3. 데이터를 저장 및 확인한다. - 경로/파일명.csv 4. 모델 학습 및 결과 출력 스크립트(~.py)를 실행한다. - 필요 라이브러리 로드 - 데이터 로드(~.csv) (~종류별 100개씩 총 500개의 ~데이터) - 학습 데이터를 8:2로 나누어 검증 데이터 생성 - 데이터별 학습 설정 - 모델 Structure 및 Instance 생성 ▷ torch의 LSTM 신경망 사용 <table><tr><th>모델 구조</th><th>Train</th><th>Valid</th><th>Test</th></tr><tr><td>Epoch</td><td>100</td><td>100</td><td>100</td></tr><tr><td>Optimizer</td><td>Adam</td><td>Adam</td><td>Adam</td></tr><tr><td>Learning-rate</td><td>0.001</td><td>0.001</td><td>0.001</td></tr><tr><td>batch_size</td><td>128</td><td>128</td><td>8</td></tr><tr><td>shuffle</td><td>True</td><td>False</td><td>False</td></tr></table> - 100 Epoch로 Accuracy가 가장 좋은 시점으로 저장하여 학습 - 평가 데이터를 활용하여 모델의 Accuracy를 평가	모델 구조	Train	Valid	Test	Epoch	100	100	100	Optimizer	Adam	Adam	Adam	Learning-rate	0.001	0.001	0.001	batch_size	128	128	8	shuffle	True	False	False
	모델 구조	Train	Valid	Test																						
	Epoch	100	100	100																						
Optimizer	Adam	Adam	Adam																							
Learning-rate	0.001	0.001	0.001																							
batch_size	128	128	8																							
shuffle	True	False	False																							
예상결과	정확도 90%이상 등 ~이상 또는 ~이하로 작성																									
예외사항	네트워크 연결 오류 등																									



(붙임)시험절차서

TVT-A-25-00XX-AG

ID	구분	내용



(붙임)시험절차서

TVT-A-25-00XX-AG

ID	구분	내용
TC2	시험 항목명	RAG + LLM 신뢰도
	시험 목표 및 기준	<시험목표> 시험대상제품의 RAG 시스템이 청크 크기 256, 오버랩 20 대비 10% 이상의 신뢰도 개선을 달성하는지 확인 <시험기준> - o 기준: RAGAS 평가 프레임워크 Faithfulness 지표 - o 산정식: $X = (B - A) / A \times 100$ - A: 기본 설정(청크 크기 256, 오버랩 2)의 Faithfulness 점수 - B: 최적화 설정(청크 크기 1000, 오버랩 50)의 Faithfulness 점수 - o 시료: NarrativeQA validation set 100개 샘플 ※ 시료는 {질문, 정답, 문서 URL} 형식의 데이터로 구성
	사전 조건	- o 운영체제: macOS 15 (Darwin 24.4.0) - o Python 3.8.6, Poetry 설치 - o 프로젝트 의존성 패키지 설치 완료 (poetry install) - o OpenAI API 키 및 LangSmith API 키 환경 변수 설정 완료 - export OPENAI_API_KEY="sk-..." - export LANGCHAIN_TRACING_V2="true" - export LANGCHAIN_ENDPOINT="https://api.smith.langchain.com" - export LANGCHAIN_API_KEY="ls_..."
	시료	"NarrativeQA Validation Dataset - 100 Samples" (LangSmith 플랫폼) - 질문, 정답, 문서 URL을 포함하는 100개의 샘플
	반복시험 횟수	각 설정별 1회 (총 2회 실행)
	시험 절차	1. 코드 저장소 클론 및 의존성 설치 - git clone https://github.com/chat-prompt/rag-optimization.git - cd rag-optimization - poetry install 2. 환경 변수 설정 확인 - OPENAI_API_KEY, LANGCHAIN_TRACING_V2, LANGCHAIN_ENDPOINT, LANGCHAIN_API_KEY 환경 변수가 정확히 설정되었는지 확인한다. 3. 기본 설정으로 실험 실행 (A 값 측정) <pre>poetry run python main.py \ --dataset_name "NarrativeQA Validation Dataset - 100 Samples" \ --model_name gpt-3.5-turbo-1106 \ --chunk_size 256 \ --chunk_overlap 20 \ --k 4</pre> 4. 최적화 설정으로 실험 실행 (B 값 측정) <pre>poetry run python main.py \ --dataset_name "NarrativeQA Validation Dataset - 100 Samples" \ --model_name gpt-3.5-turbo-1106 \ --chunk_size 1000 \</pre>



(붙임)시험절차서

TVT-A-25-00XX-AG

ID	구분	내용
		--chunk_overlap 50 \ --k 4 5. 결과 분석 및 개선율 계산 - 산정식 $X = (B - A) / A \times 100$ 을 사용하여 신뢰도 개선율을 계산한다.
	예상결과	신뢰도 개선율(X) $\geq 10\%$
	예외사항	- OpenAI API 서비스 응답 지연 또는 오류 - LangSmith 플랫폼 접속 또는 로깅 오류 - 네트워크 연결 불안정 - 실행 환경의 예기치 않은 문제로 인한 스크립트 중단



(붙임)시험절차서

TVT-A-25-00XX-AG

ID	구분	내용
TC3	시험 항목명	파인튜닝 LLM 정확도
	시험 목표 및 기준	<시험목표> 파라미터 수가 70억개 이하인 오픈소스 LLM을 한국어 데이터셋으로 파인튜닝한 후, KoBEST HellaSwag 벤치마크에서의 성능 개선 확인 <시험기준> - o 기준: KoBEST HellaSwag 벤치마크의 F1 점수 - o 산정식: $X = F1 \times 100$ - F1: EleutherAI의 lm-evaluation-harness로 측정된 KoBEST HellaSwag의 F1 점수 - 10-shot 설정으로 평가 수행 - o 평가 명령어: <code>lm_eval --model hf --model_args pretrained={기본모델},peft={파인튜닝모델},parallelize=True --tasks kobest --num_fewshot 10 --batch_size auto</code>
	사전 조건	- o AWS G5 인스턴스(g5.12xlarge) 환경 구성 완료 - o RHEL 8.9 및 CUDA 12.3 설치 - o Python 3.8 이상, Git, Git LFS, Poetry 설치 - o 필요 패키지 설치 완료: - transformers 4.31.0 - lm-eval 0.4.2(wandb 연동) - bitsandbytes 0.43.0 - wandb 0.16.5 - o Hugging Face 계정 및 토큰 설정
	시료	- o 기본 모델: beomi/open-llama-2-ko-7b (Hugging Face) - o 파인튜닝된 모델: youngwook-kim/open-llama-2-ko-7b-ko-alpaca-finetuned-50steps - o 평가 데이터셋: KoBEST 벤치마크
	반복시험 횟수	1회
	시험 절차	1. 환경 변수 설정 - <code>export HF_TOKEN=your_hf_token_here</code> 2. 코드 저장소 클론 및 의존성 설치 - <code>git clone https://github.com/chat-prompt/ko-llm-ft</code> - <code>cd ko-llm-ft</code> - <code>pip3.8 install --user --requirement <(poetry export --format requirements.txt --without-hashes)</code> 3. 파인튜닝된 모델 평가 <pre>lm_eval --model hf --model_args pretrained=beomi/open-llama-2-ko-7b,peft=youngwook-kim/open-llama-2-ko-7b-ko-alpaca-finetuned-50steps,parallelize=True --tasks kobest --num_fewshot 10 --batch_size auto --wandb_args project=geniefy</pre> 4. 결과 확인 및 분석 - 평가 결과에서 KoBEST HellaSwag의 F1 점수 확인



(붙임)시험절차서

TVT-A-25-00XX-AG

ID	구분	내용
	예상결과	KoBEST HellaSwag 벤치마크의 F1 점수 47.4% 이상
	예외사항	- GPU 메모리 부족 - 네트워크 연결 오류 - Hugging Face 또는 Weights & Biases 서버 접속 불가 - 모델 크기 제한으로 인한 처리 오류