

Whisper-AT 논문 리뷰

☒ 발표 할 것 ☐

Paper : <https://arxiv.org/abs/2307.03183>

Whisper-AT: Noise-Robust Automatic Speech Recognizers are Also Strong General Audio Event Taggers

Abstract

Whisper는 다양한 환경에서 수집된 68만 시간의 대규모 음성 데이터를 학습하여 잡음에 강한 ASR 모델이다. 그러나 Whisper의 표현은 잡음-불변이 아닌 잡음-조건적이며, 이는 다양한 비음성(background) 소리를 인코딩한다는 것을 의미한다. 이 특성을 이용해 Whisper의 인코더를 고정하고, 경량 오디오 태깅 모듈을 추가하여 Whisper-AT를 설계하였다. 이 모델은 추가 연산량 1% 미만으로 음성과 소리 태깅을 동시에 처리할 수 있다.

1. Introduction

기존 ASR 연구들은 깨끗한 음성 데이터(LibriSpeech 등)를 기반으로 학습되어 실제 환경 잡음에 취약했다. Whisper는 이를 극복하기 위해 다양한 조건의 대규모 데이터를 학습하며, 잡음에 강건한 성능을 보인다. 그러나 본 논문은 Whisper가 일반적인 기대와 달리 잡음을 제거하지 않고, 이를 인코딩한 후 잡음 조건에 따라 음성을 인식한다는 점을 밝히고, 이를 활용한 오디오 태깅 응용 가능성을 제시한다.

2. Whisper Robust ASR Model

Whisper는 Transformer 기반 인코더-디코더 구조이며, 학습 데이터가 핵심 강점이다. 68만 시간의 인터넷 수집 데이터는 기존 오디오북 기반보다 훨씬 다양하지만 라벨 노이즈가 있다. 본 논문에서는 Whisper-Large 인코더만을 사용하며, 총 32개 레이어로 구성되어 있다. Whisper는 비록 음성 텍스트 페어만 학습했지만, 비음성 정보를 풍부하게 내포한다.

3. Noise-Robust ASR Learns Noise-Variant Representations

Whisper는 잡음에 강하지만, 표현은 잡음을 제거하는 대신 적극적으로 인코딩한다. 실험적으로 Whisper 표현을 통해 ESC-50 환경을 분류를 시도한 결과, 타 모델 대비 가장 높은 분류 정확도를 보였다. 또한 소리 인식 성능이 높을수록 해당 소리에 대한 음성 인식 강건성도 증가하는 양의 상관관계를 확인했다. 이는 Whisper가 잡음-조건적 인식을 수행함을 보여준다.

4. Unifying ASR and Audio Tagging Model

Whisper 표현이 잡음 정보를 담고 있으므로, 이를 기반으로 오디오 태깅을 수행할 수 있다. Whisper-AT는 Whisper 인코더를 그대로 두고, 오디오 태깅 전용 경량 모듈을 추가한 구조다. 다양한 설계 방식(Last-MLP, WA-MLP, WA-Tr, TL-Tr)을 실험하였으며, TL-Tr은 시간 + 레이어 축의 Transformer를 활용해 가장 우수한 성능을 보였다. 계산량은 Transformer 크기 축소와 pooling 등을 통해 효과적으로 억제되었다.

5. Experiments

AudioSet 및 ESC-50을 대상으로 오디오 태깅 실험을 수행했다. Whisper-AT는 기존 ASR 기반 모델보다 훨씬 강력하며, 독립형 오디오 태깅 모델보다 약간 성능이 낮지만 계산량이 매우 적다. 특히 TL-Tr512는 SOTA AT 모델 대비 42배 빠르고 11배 작으며, AS-2M에서 41.5 mAP, ESC-50에서 91.7% 정확도를 달성했다. 모델 크기별 분석 결과 Whisper-Small도 준수한 성능을 보였으며, 잡음 강건성과 태깅 성능이 모델 크기와 정비례하는 경향을 보였다.

6. Conclusion

Whisper는 잡음 정보를 제거하지 않고 인식 과정에 조건으로 활용하는 방식을 채택한다. 이로 인해 오디오 이벤트 인식 능력도 자연스럽게 확보하며, Whisper-AT는 이러한 특성을 활용한 통합 멀티태스킹 모델이다. Whisper-AT는 텍스트 전사와 오디오 태깅을 동시에 수행하면서도 계산 비용은 매우 적으며, 현실적인 응용 가능성이 높은 모델로 평가된다.

모델 구조도 요약




Figure 4: *The proposed time and layer-wise Transformer model.*

Whisper-AT는 Whisper 인코더 위에 가볍고 효과적인 오디오 태깅 모듈을 결합한 구조다.

Whisper-AT 주요 구조

- **Whisper 인코더**: 32개의 Transformer 블록, frozen 상태로 사용
- **Temporal Pooling**: 시퀀스 길이를 500 → 25로 축소
- **Linear Projection (선택 사항)**: 차원 수 1280 → 512 축소
- **Temporal Transformer**: 시간 축의 패턴 모델링
- **Layer-wise Transformer**: 소리 클래스마다 최적의 레이어 가중치를 학습
- **분류기(MLP)**: 오디오 태깅 라벨 출력
- Whisper 디코더는 사용하지 않으며, 텍스트 전사와 소리 태깅을 동시에 출력

실험 결과 그림 요약

그림 1: 잡음 강건성 vs 오디오 분류 능력




Figure 1: Surprisingly, the noise robustness of an ASR model correlates **positively** to the amount of general background sound (noise for ASR) information encoded in their intermediate representations. In the upper figure, we show Whisper is noticeably more robust (smaller word error rate increase) when speech (Librispeech) is contaminated with an increasing amount of background sounds from ESC-50 [6]. In the lower figure, we show the intermediate representations of Whisper lead to the best linear probing sound classification accuracy on the same ESC-50 data, indicating Whisper encodes most background sound information. Unlike other models, Whisper encodes background sound information even in its deepest layer. PR=self-supervised pretrained; FT=PR and fine-tuned model.

- Whisper는 ESC-50 배경 소음이 증가해도 WER 상승폭이 작음
- 중간 표현으로 ESC-50 클래스 분류 시 정확도도 최고

그림 2: 소리 인식 능력 vs 잡음에 대한 ASR 강건성




Figure 2: Class-wise analysis of the relationship between Whisper’s robustness against a specific background sound class and its potential ability to recognize the sound. We measure Whisper robustness by its WER increase from clean speech (20dB SNR) to speech contaminated by the specific background sound from ESC-50 (-10dB SNR). The lower the WER increase, the more robust the model (Y-axis). We estimate the potential ability of Whisper to recognize the sound by training a linear layer on top of the Whisper encoder’s last-layer representation for the sound classification task on the same ESC-50 dataset (without speech mixed-in, the Whisper model is frozen) and show the class-wise F1-score. The higher the F1-score, the better Whisper can potentially recognize the sound class (X-axis). Blue dashed line: we observe a positive correlation between Whisper’s robustness against a background sound type and its potential ability to recognize it. Blue shading: we observe most sound classes lie in the right-bottom triangle area, indicating that Whisper is not robust to the type of sound if it cannot recognize the sound type. Right-bottom outliers: there are some background sounds that Whisper can potentially recognize but is not robust to, which is expected as some noises heavily overlap with the speech and are impossible to be robust to. In short, we find the potential ability to recognize a sound type is a necessary but not sufficient condition for Whisper to be robust to it.

- 소리를 잘 인식할수록 WER 증가폭이 작아짐 → 양의 상관관계 존재

그림 3: 소리 클래스별로 가장 잘 작동하는 Whisper 레이어 분포




Figure 3: *Histogram of the best Whisper representation layer (1-32) for the 50 ESC-50 sound classes. We train a linear layer on top of the representation of each of the 32 Whisper layers for ESC-50 sound classification, compute the class-wise F1-Score, and find the best representation layer for each sound class. Different sound classes get the best F1-score on representations of different layers.*

- 소리마다 최적의 레이어가 다름 → 복합적 레이어 활용 필요성 시사

그림 4: Whisper-AT 전체 구조 시각화




Figure 4: The proposed time and layer-wise Transformer model.

- Whisper 인코더 출력 → 평균 풀링 → 차원 축소 → 시간 Transformer → 레이어 Transformer → 오디오 라벨 출력

그림 5: Whisper 모델 크기별 성능 비교




Figure 5: AS-2M audio tagging performance (left) and ASR robustness (right) of the Whisper model family.

- Whisper-Large가 성능 최고
- Whisper-Base도 HuBERT-XLarge보다 오디오 태깅 및 ASR 잡음 강건성에서 우수함

표 요약

표 1: 오디오 태깅 성능 비교 (AS-20K, AS-2M, ESC-50)

모델	방식	AS-20K mAP	AS-2M mAP	ESC-50 정확도	추가 파라미터	속도 비율
Whisper-AT (TL-Tr512)	Frozen	32.8	41.5	91.7	7M	42× 빠름
AST (SOTA AT 모델)	E2E	34.7	45.9	88.8	87M	1× 기준

→ Whisper-AT는 성능이 약간 낮지만 40배 이상 빠르고 훨씬 작음

표 2: Transformer 차원(d)에 따른 성능 및 연산량

d	mAP	ESC-50 정확도	FLOPs(G)
128	30.0	91.4	0.31
256	32.0	92.0	0.94
512	32.8	91.7	3.17
1280	33.0	91.1	16.42

→ 성능은 대체로 차원에 따라 증가하지만, 512 수준에서도 충분히 우수함