

Whisper 논문 리뷰

☒ 발표 할 것 ☐

Paper : <https://arxiv.org/abs/2212.04356>

Robust Speech Recognition via Large-Scale Weak Supervision (OpenAI, 2022)

Abstract

Whisper는 68만 시간에 달하는 웹 기반 오디오-텍스트 데이터로 학습된 **멀티태스크 음성 인식 모델**이다. 다국어, 다작업, 다양한 환경에서 **제로샷(Zero-shot)** 상태에서도 우수한 성능을 보이며, 인간 수준의 견고성과 정확도를 지닌다. 전체 모델과 추론 코드를 공개하였다.

1. Introduction

기존 음성 인식 모델들은 비지도 사전학습이나 도메인별 미세조정에 의존해 왔다. Whisper는 데이터 규모 자체의 확장을 통해 별도 조정 없이 **범용적이고 견고한** 성능을 달성하고자 한다. 이 모델은 96개 언어와 음성 번역, 전사 등 다양한 작업을 아우르는 **멀티태스크 + 멀티링귄 모델**이다.

2. Approach

- **데이터 처리**: 인터넷 자막 데이터를 활용하며, 기계 전사 탐지 및 필터링, 언어 정렬을 통해 품질 확보.
- **모델 구조**: 인코더-디코더 Transformer 기반, 5가지 크기 (Tiny~Large).
- **멀티태스크 포맷**: 작업 토큰을 통해 전사/번역/타임스탬프 등을 제어.
- **훈련**: 30초 오디오 단위, 대규모 데이터셋에서 감독 학습으로 학습.
→ 비지도 사전학습 없이도 높은 일반화 성능 확보.

3. Experiments

- **영어 전사**: LibriSpeech에서 기존 SOTA보다 낮지만, 현실 환경에선 **더 강한 일반화** 성능.
- **다국어 전사**: MLS에서 SOTA 달성, VoxPopuli에선 데이터 분포 차이로 성능 하락.

- **언어 식별:** 전체 정확도는 낮지만, 훈련된 언어에 한해선 80% 이상 정확도.
 - **잡음 견고성:** Whisper는 소음 조건에서 기존 모델 대비 **압도적인 성능 우위**.
 - **장문 오디오 처리:** 반복/누락 오류 대응을 위한 휴리스틱 디코딩 전략 도입.
 - **인간 비교:** 평균 WER에서 인간과 비슷하지만, 오류 유형과 문맥 이해에서 차이 있음.
-

4. Analysis and Ablations

- **오류 분석:** 반복, 삽입, 환각, 스타일 오류 등 Whisper 고유의 오류 경향 확인.
 - **도메인 전이:** 일부 벤치마크에서 도메인 불일치로 성능 저하 발생.
 - **정규화 효과:** 형식 차이에 민감한 WER 한계를 지적하고 새로운 평가 기준 필요성 제안.
 - **의미 기반 평가지표 개발 필요성 강조.**
-

5. Related Work

- **음성 인식:** 자기지도 학습(Wav2Vec 등)과 다도메인 감독 학습의 두 갈래. Whisper는 후자를 확장.
 - **약한 감독:** 웹 기반 대규모 noisy 데이터를 활용한 훈련 방식은 비전/NLP에서도 효과적임.
 - **멀티태스크 모델:** GPT-3, T5처럼 Whisper도 다양한 작업을 단일 시퀀스로 수행 가능하게 설계됨.
-

6. Limitations and Future Work

1. 디코딩 전략 개선 필요

- 장문 전사에서 반복 루프, 앞/뒤 단어 누락, 오디오와 무관한 환각 등 문제가 존재.
- 제안: 고품질 데이터로 **파인튜닝, 강화학습** 기반 디코딩 최적화.

2. 저자원 언어 데이터 부족

- 대부분 언어는 1000시간 미만 데이터 보유. 성능은 데이터 양에 비례.
- 제안: **드문 언어 데이터 확대**로 전체 성능 향상 기대.

3. 파인튜닝 연구 미진

- 현재는 제로샷 성능만 분석.
- 고품질 감독 데이터에서 파인튜닝 시 **추가 성능 향상 및 비교 가능성** 있음.

4. 디코더/인코더 구성 요소 영향 분석 필요

- Whisper의 견고성이 어디서 기인하는지 명확하지 않음.
- 제안: 디코더 없는 모델 등으로 **구성요소 제거 실험(ablation)** 수행.

5. 보조 학습 목표 미사용

- 자기지도 사전학습이나 self-training 없이도 성능 확보했지만,
- 향후 **추가 기법 통합** 시 더 높은 성능 가능성 있음.

7. Conclusion

Whisper는 약한 감독과 데이터 규모 확장만으로 **범용 음성 인식 시스템**이 가능하다는 것을 입증했다. 다양한 언어와 작업에서 강인한 제로샷 성능을 보여주며, 연구 커뮤니티와 산업계에 **강력한 출발점**을 제공한다. 모델 및 코드가 공개되어 있으며, 향후 발전 가능성이 크다.

Whisper 모델 구조 요약 (Architecture Overview)

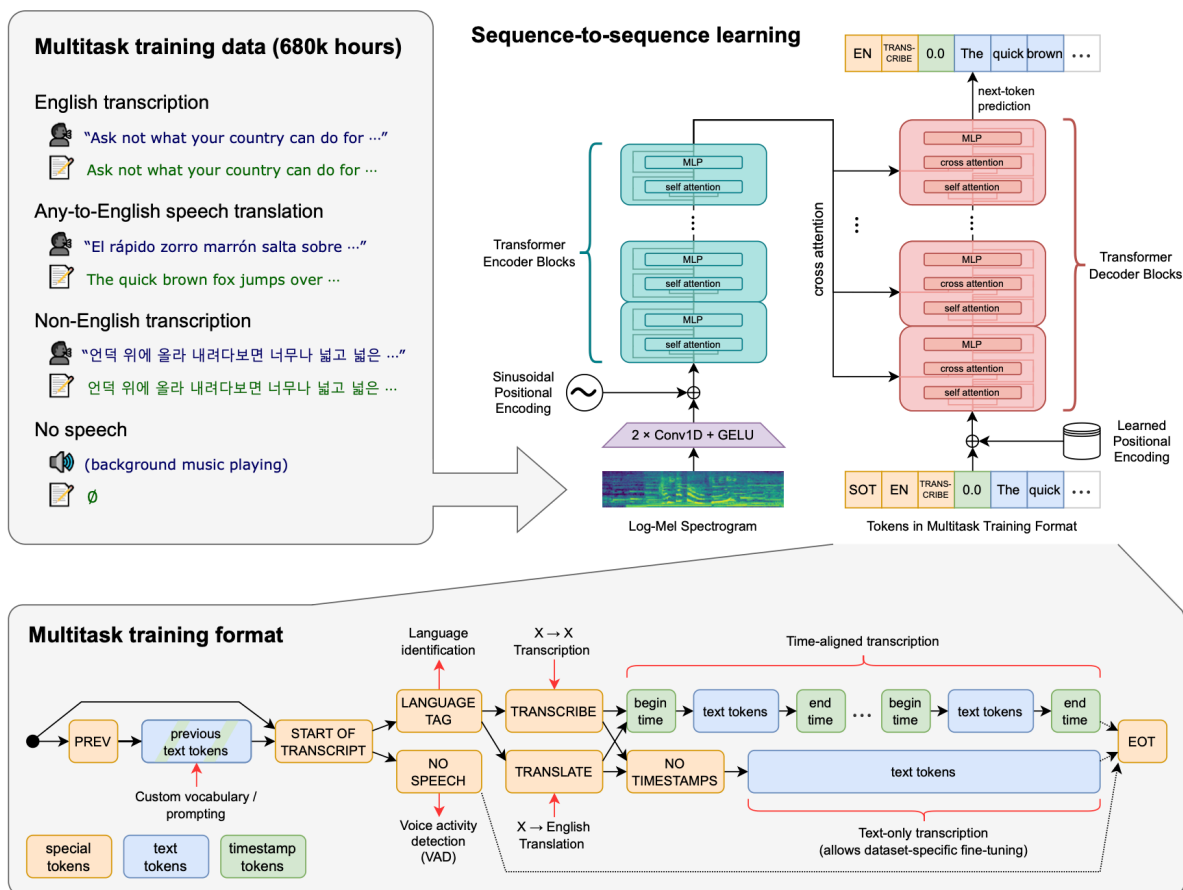


Figure 1. **Overview of our approach.** A sequence-to-sequence Transformer model is trained on many different speech processing tasks, including multilingual speech recognition, speech translation, spoken language identification, and voice activity detection. All of these tasks are jointly represented as a sequence of tokens to be predicted by the decoder, allowing for a single model to replace many different stages of a traditional speech processing pipeline. The multitask training format uses a set of special tokens that serve as task specifiers or classification targets, as further explained in Section 2.3.

Whisper는 **인코더-디코더 Transformer 기반 시퀀스-투-시퀀스** 모델입니다.

아래는 구조와 흐름을 간단히 나타낸 요약입니다:

1. 입력 처리 흐름

오디오 입력:

- **Raw Audio** → 16kHz 리샘플
- → **로그-멜 스펙트로그램 변환** (80채널, 25ms 윈도우, 10ms 스트라이드)

2. 인코더 (Encoder)

구성:

- 2개의 1D 컨볼루션 (Conv1D) 레이어

- GELU 활성화
 - 스트라이드로 다운샘플링
 - 사인 위치 임베딩 (Sinusoidal Positional Embedding) 추가
 - N개의 Transformer 인코더 블록 (모델 크기에 따라 다름)
 - 마지막에 LayerNorm
-

3. 디코더 (Decoder)

입력:

- `<|startoftranscript|>`, `<|lang|>`, `<|transcribe|>/<|translate|>`, `<|notimestamps|>` 등의 제어 토큰
- 이전 디코딩된 텍스트 (자기 회귀 구조)

구성:

- 학습된 위치 임베딩
- 입력 임베딩과 출력 임베딩을 공유
- N개의 Transformer 디코더 블록
- 디코더는 오디오 인코딩을 **cross-attention**으로 참조

출력:

- 텍스트 토큰 + (옵션) 타임스탬프 토큰
-

4. 멀티태스크 포맷

- Whisper는 다양한 작업을 하나의 시퀀스 모델로 처리
 - 작업 지정 토큰을 통해 다음을 제어:
 - 언어 식별
 - 전사 / 번역
 - 타임스탬프 포함 여부
 - 무음 감지 (`<|nospeech|>`)
-

5. 모델 크기별 구성 (요약표)

모델	층 수	폭(width)	파라미터 수
Tiny	4	384	39M
Base	6	512	74M
Small	12	768	244M
Medium	24	1024	769M
Large	32	1280	1550M

이 구조는 Whisper가 길이 가변 입력, 다중 언어, 다중 작업을 유연하게 처리할 수 있도록 설계되어 있습니다.

Whisper 주요 실험 결과 요약

1. 영어 음성 인식 (ASR) – WER (%) 비교

데이터셋	기존 모델 (Best)	Whisper (Zero-shot)
LibriSpeech (test-clean)	1.4 (SOTA)	5.7
TED-LIUM 3	6.3	5.2
Common Voice (EN)	10.3	7.6
CHiME-6	81.3	37.4

해석: LibriSpeech에서는 기존 SOTA보다 성능이 낮지만,
잡음/현실 환경에서는 월등히 우수한 견고성 발휘

2. 다국어 음성 인식 (Multilingual ASR)

Multilingual LibriSpeech (WER %)

모델	평균 WER
XLS-R (1B)	10.9
mSLAM-CTC (2B)	9.7
Whisper	7.3

VoxPopuli (WER %)

모델	평균 WER
Maestro	8.1

Whisper	13.6
---------	-------------

Whisper는 MLS에서는 SOTA 수준,
VoxPopuli에서는 훈련 분포와 달라 성능 저하

3. 언어 식별 (Language ID) – 정확도 (%)

모델	Fleurs Accuracy
mSLAM-CTC (2B)	77.7
Whisper	64.5

Whisper는 훈련되지 않은 언어 포함으로 평균 낮음.
훈련 언어에 한하면 정확도 80.3%

4. 잡음 견고성 (Noise Robustness) – LibriSpeech WER (%)

백색 잡음 조건 (SNR = 5 dB)

모델	WER
Wav2Vec2	78.0
Whisper	22.3

펍 잡음 조건 (SNR = 5 dB)

모델	WER
Wav2Vec2	85.4
Whisper	27.5

Whisper는 현실 잡음 환경에서 큰 성능 차이로 기존 모델을 압도

5. 인간 vs Whisper (LibriSpeech **test-clean**)

전사자	WER (%)
인간 평균	5.8
Whisper Large	5.7

정량적 성능은 인간 수준에 도달했으나,
오류 유형과 추론 능력에서 차이 존재

Figure 11: Whisper 학습 데이터셋 통계 요약




Figure 11. Training dataset statistics

◆ 총 데이터 구성 비율

- 영어 음성 인식 (English Speech Recognition):
약 438,218시간, 전체의 65%
- 음성 → 영어 번역 (Speech Translation to English):

약 125,739시간, 전체의 18%

- **다국어 음성 인식 (Multilingual Speech Recognition):**

약 117,113시간, 전체의 17%

◆ 언어별 데이터 분포 (일부 샘플)

데이터 분포는 언어별 심한 불균형을 보여주며, 대부분의 언어는 수십수백 시간 수준, 상위 언어는 수천수만 시간에 이릅니다.

상위 리소스 언어 (High-resource)

- **Chinese (중국어):** 23,446시간
- **German (독일어):** 13,344시간
- **Spanish (스페인어):** 11,100시간
- **Russian (러시아어):** 9,761시간
- **French (프랑스어):** 9,752시간
- **Korean (한국어):** 7,993시간
- **Japanese (일본어):** 7,054시간

▼ 저자원 언어 (Low-resource, 예시)

- **Turkmen:** 1시간
 - **Bashkir:** 1시간
 - **Malagasy:** 2시간
 - **Uzbek:** 4시간
 - **Tajik:** 15시간
 - **Amharic:** 32시간
 - **Sindhi:** 46시간
-

◆ 시사점

- Whisper는 다양한 언어로 구성되어 있지만, **상위 언어(특히 영어 중심)**에 편중된 학습 데이터를 기반으로 하고 있음
- **훈련 데이터 양과 성능 간 상관관계는 매우 높으며 (Figure 3 기준 $R^2 = 0.83$),**

저자원 언어는 제로샷 성능에서도 **취약한 경향**을 보임